



Escuela de
Ingeniería,
Arquitectura
& Diseño



Universidad
Tecnológica
de Bolívar

Modelo Analítico para la Caracterización y Predicción de la Demanda de Emergencias en la Red de Distribución de Gas Natural en Montería, Córdoba, mediante Técnicas de Analítica de Datos

Engineering Project Final Report

German Eduardo De Armas Castaño <gdearmas@utb.edu.co >
Sebastián Enrique Delgado Solano <delgados@utb.edu.co>
Angel Luis Vega Rodríguez <anvega@utb.edu.co>

Project Advisors:

Advisor 1

Advisor 2

Course Advisor:

Carlos Martin Ferreira
Vanegas

Program:

Industrial Engineering

May 7, 2025

Table of Contents

Abstract

1	Problem Statement	5
1.1	Needs	5
1.2	Objectives	6
1.3	Operational Environment	7
1.4	Requirements	8
1.5	Intended Users and Uses	11
1.6	Assumptions and Limitations	13
1.7	Expected End Product and Deliverables	16
1.8	Background and Literature Survey	17
2	Conceptual Design	33
2.1	Product System Design Decomposition	33
2.2	Evaluation of Design Alternatives	36
2.3	References	45

Abstract

The project "Analytical model for the characterization and prediction of emergency demand in the natural gas distribution network in Montería, Córdoba" addresses the challenge of managing emergency events such as leaks, service interruptions, and operational failures, which require efficient and timely resource allocation.

Currently, emergency management is primarily reactive, limiting the ability to anticipate demand patterns and optimize operational planning. To address this, the project proposes the development of an analytical model based on statistical and machine learning techniques, capable of identifying patterns in historical data and predicting future emergency demand.

The system is validated using quantitative metrics such as MAE, RMSE and MAPE, and its results are presented through an interactive dashboard that facilitates operational interpretation for different user profiles within the organization.

The outcome of this work is a functional analytical system — a predictive model, a data pipeline, and an interactive dashboard — designed to give gas distribution operators in intermediate Colombian cities a practical tool for anticipating emergencies rather than simply reacting to them.

This work contributes to the operational intelligence of natural gas distribution companies in intermediate cities like Montería, Colombia, by providing a predictive model, a data processing pipeline, and an interactive dashboard that collectively enable a measurable shift from reactive to proactive emergency management.

Resumen

El proyecto “Modelo analítico para la caracterización y predicción de la demanda de emergencia en la red de distribución de gas natural en Montería, Córdoba” aborda el desafío de gestionar eventos de emergencia como fugas, interrupciones del servicio y fallas operativas, que requieren una asignación eficiente y oportuna de recursos.

Actualmente, la gestión de emergencias es principalmente reactiva, lo que limita la capacidad de anticipar patrones de demanda y optimizar la planificación operativa. Para abordar esto, el proyecto propone el desarrollo de un modelo analítico basado en técnicas estadísticas y de aprendizaje automático, capaz de identificar patrones en datos históricos y predecir la demanda de emergencia futura.

El sistema se valida mediante métricas cuantitativas como MAE, RMSE y MAPE, y sus resultados se presentan a través de un dashboard interactivo que facilita la interpretación operativa para distintos perfiles de usuario dentro de la organización.

Los principales productos desarrollados incluyen un modelo predictivo implementado en Python, un canal de procesamiento de datos estructurados y un panel interactivo para visualización y soporte de decisiones.

Este trabajo contribuye a la inteligencia operativa de las empresas de distribución de gas natural en ciudades intermedias como Montería, Colombia, al proporcionar un modelo predictivo, un proceso de procesamiento de datos y un panel interactivo que en conjunto permiten un cambio de una gestión de emergencias reactiva a una proactiva.

1 Problem Statement

1.1 Needs

Gestionar emergencias en una red de distribución de gas no es un problema que aparezca y desaparezca: es una presión constante. Fugas, interrupciones del servicio y fallas operativas. En ciudades como Montería, Córdoba, estas situaciones representan un desafío constante para la operación, debido a la variabilidad en la ocurrencia de los eventos y a la necesidad de responder de manera oportuna para garantizar la continuidad del servicio y la seguridad de los usuarios. Estas emergencias no solo implican riesgos operativos, sino que también pueden generar impactos económicos asociados a la movilización de recursos, tiempos de respuesta prolongados y afectaciones en la calidad del servicio prestado.

Pese a la magnitud de este desafío, la gestión de estas emergencias se realiza actualmente de manera predominantemente reactiva, en la cual la asignación de recursos técnicos se lleva a cabo una vez ocurrido el evento. Si bien las empresas cuentan con indicadores operativos que permiten monitorear el comportamiento histórico de las emergencias, estos son de carácter descriptivo y no permiten anticipar la demanda futura del servicio. Esta limitación dificulta la planificación eficiente de las cuadrillas de atención, el uso óptimo de los recursos disponibles y la implementación de estrategias preventivas. Adicionalmente, la red de distribución se encuentra expuesta a múltiples factores externos como condiciones climáticas, características urbanas y dinámicas poblacionales. Estos factores no solo aumentan la complejidad operativa del sistema, sino que también pueden comprometer la seguridad de los habitantes y afectar la calidad de vida de comunidades enteras cuando las emergencias no son atendidas oportunamente. La ausencia de herramientas analíticas que permitan relacionar estos factores con la demanda de emergencias genera una brecha crítica en la gestión operativa, limitando la capacidad de las organizaciones para anticiparse a los eventos y tomar decisiones informadas. En este contexto, el presente proyecto propone desarrollar un modelo analítico que permita comprender y caracterizar el comportamiento de la demanda de emergencias, orientando la toma de decisiones hacia un enfoque preventivo y fundamentado en datos.

1.2 Objectives

Objetivo General

Desarrollar un modelo analítico predictivo basado en técnicas de análisis estadístico y aprendizaje automático en Python, complementado con un dashboard interactivo, que permita caracterizar e identificar los patrones espaciales y temporales de la demanda de emergencias en la red de distribución de gas natural en Montería, Córdoba, con el propósito de fortalecer la planificación operativa, optimizar la asignación de recursos técnicos y mejorar la eficiencia en la atención de eventos.

Objetivos Especificos

1. Analizar y caracterizar el comportamiento histórico de la demanda de emergencias en la red de distribución de gas natural mediante técnicas de análisis exploratorio y descriptivo de datos, con el fin de identificar patrones espaciales y temporales, clasificar los tipos de eventos y comprender los factores que influyen en su ocurrencia.
2. Diseñar la estructura conceptual y analítica de un modelo predictivo basado en técnicas de aprendizaje automático, que permita estimar la demanda de emergencias en la red de distribución, considerando variables operativas, temporales, geográficas y ambientales relevantes.
3. Definir la arquitectura metodológica para la implementación de modelos predictivos en Python, evaluando y seleccionando los enfoques más adecuados según las características del conjunto de datos, e incluyendo los procesos de entrenamiento, validación cruzada y evaluación del desempeño.
4. Diseñar un dashboard interactivo que permita visualizar los patrones de demanda de emergencias, identificar zonas y periodos críticos, y facilitar la interpretación de los resultados del modelo para apoyar la toma de decisiones operativas.
5. Diseñar un esquema de evaluación del desempeño del modelo predictivo mediante métricas cuantitativas como MAE, RMSE y MAPE, e incluir un análisis de impacto operativo que estime, con base en los resultados obtenidos, las mejoras potenciales en la eficiencia de la atención de emergencias y la optimización de recursos técnicos.

1.3 Operational Environment

Entorno Operativo del Proyecto

El modelo analítico propuesto se desarrollará para su aplicación en el contexto técnico y operativo de la red de distribución de gas natural en Montería, Córdoba, la cual abarca zonas urbanas con dinámicas de crecimiento poblacional y actividad económica variables. No obstante, el sistema se encuentra influenciado por diferentes entornos que condicionan su funcionamiento y desempeño:

1. Entorno Ambiental: El sistema operará bajo condiciones ambientales propias de la región Caribe colombiana, caracterizadas por:

- Altas temperaturas promedio (entre 28 °C y 35 °C) y elevados niveles de humedad relativa.
- Periodos de lluvias intensas que pueden afectar la estabilidad del terreno y la operación de la infraestructura.
- Variabilidad en las condiciones del suelo, incluyendo zonas con suelos arcillosos, arenosos y de relleno urbano, que influyen en el comportamiento de la red.
- Entornos urbanos con alta densidad poblacional y actividad constructiva, que pueden incidir indirectamente en la ocurrencia de eventos de emergencia.

Estos factores influyen en la frecuencia y distribución de las emergencias, por lo que deben ser considerados dentro del modelo analítico.

2. Entorno Tecnológico: El desarrollo del sistema se plantea sobre una infraestructura tecnológica orientada al análisis de datos, que incluye:

- Lenguaje de programación Python para el procesamiento de datos, desarrollo de modelos predictivos y análisis estadístico.
- Librerías especializadas en ciencia de datos y aprendizaje automático (como Scikit-learn y TensorFlow).
- Herramientas de visualización para la construcción de dashboards interactivos.

- Bases de datos operativas con registros históricos de emergencias, incluyendo variables temporales, geográficas y operativas.
- Infraestructura computacional capaz de soportar el procesamiento y almacenamiento de datos, así como la integración de fuentes externas.

3. Entorno Organizacional y Operativo: El sistema está orientado a apoyar la toma de decisiones dentro de diferentes áreas de la organización, entre ellas:

- Equipos operativos y técnicos encargados de la atención de emergencias y mantenimiento de la red.
- Áreas de planeación operativa responsables de la asignación de recursos y programación de actividades.
- Analistas de datos y personal de innovación, encargados de interpretar los resultados del modelo y generar estrategias basadas en información.

La integración de este modelo en el entorno organizacional no solo permitirá una transición hacia un enfoque más proactivo en la gestión de emergencias, sino que también sentará las bases para la implementación de estrategias de mantenimiento predictivo y planificación operativa basada en datos dentro de la empresa distribuidora.

1.4 Requirements

1. Requisitos Funcionales

- *Desarrollo del modelo predictivo*: El sistema deberá permitir la construcción de un modelo predictivo basado en datos históricos de emergencias en la red de distribución de gas natural, incluyendo variables temporales, geográficas, operativas y ambientales.
- *Predicción de la demanda de emergencias*: El modelo deberá estimar la cantidad de emergencias esperadas en un periodo determinado (por ejemplo, día, semana o mes), así como su distribución espacial por zonas de la ciudad de Montería.
- *Identificación de zonas y periodos críticos*: El sistema deberá identificar las zonas geográficas y los intervalos de tiempo con mayor probabilidad de ocurrencia de

emergencias, con el fin de priorizar la asignación de recursos técnicos.

- *Caracterización de patrones:* El modelo deberá permitir analizar patrones históricos de la demanda de emergencias, incluyendo: estacionalidad, tendencias, frecuencia por tipo de evento, relación con variables externas (clima, urbanización, entre otras variables relevantes)
- *Visualización interactiva:* Se deberá incluir un dashboard interactivo que permita: visualizar mapas de calor de emergencias, identificar zonas críticas, analizar tendencias temporales e interpretar resultados del modelo.
- *Integración de fuentes de datos:* El sistema deberá ser compatible con las bases de datos internas de la empresa (histórico de emergencias, registros operativos y capas GIS), así como con fuentes externas de acceso público que aporten variables climáticas, geográficas y socioeconómicas relevantes para el modelo.
- *Generación de reportes:* El sistema deberá generar reportes automáticos con: indicadores de demanda, predicciones futuras, zonas críticas y desempeño del modelo.

2. Requisitos Económicos / Operativos

- *Optimización de recursos:* El modelo deberá contribuir a mejorar la planificación operativa mediante una asignación más eficiente de cuadrillas, vehículos y recursos técnicos.
- *Reducción de costos operativos:* El modelo deberá contribuir a disminuir los costos asociados a tiempos de respuesta prolongados, desplazamientos no optimizados y subutilización de recursos técnicos derivada de una planificación insuficiente.
- *Uso de herramientas de código abierto:* Python, librerías de machine learning y herramientas de visualización para evitar costos adicionales por licencias.
- *Impacto en la eficiencia operativa:* Se deberán definir indicadores que permitan evaluar mejoras en: tiempos de atención, utilización de recursos y cobertura del servicio.

3. Requisitos Ambientales

- *Consideración de variables ambientales:* El modelo deberá incorporar variables como: temperatura, precipitación y humedad para analizar su influencia en la ocurrencia de emergencias.
- *Análisis indirecto de impacto:* El sistema deberá permitir evaluar cómo una mejor planificación: reduce desplazamientos innecesarios y mejora la eficiencia operativa (lo cual tiene impacto ambiental indirecto).
- *Uso de datos geográficos y climáticos:* Se deberán integrar fuentes externas que permitan enriquecer el modelo con variables del entorno físico.

4. Requisitos de Interfaz de Usuario

- *Interfaz intuitiva:* El sistema deberá contar con una interfaz clara que permita a usuarios no técnicos interpretar fácilmente: mapas, gráficos y predicciones.
- *Dashboard interactivo:* Debe incluir filtros por zona, fecha y tipo de evento, visualización de tendencias y mapas geoespaciales.
- *Compatibilidad:* El sistema deberá ser accesible desde navegador web y equipos de escritorio.

5. Requisitos de Seguridad y Escalabilidad

- *Seguridad de la información:* El sistema deberá garantizar la protección de la información sensible de Surtigas, utilizando protocolos de seguridad adecuados.
- *Escalabilidad del modelo:* El diseño deberá permitir la incorporación de nuevas variables, regiones o periodos de tiempo sin requerir una reestructuración completa del sistema.
- *Validación y evaluación:* El modelo deberá someterse a pruebas de validación (precisión, sensibilidad, error de predicción) antes de su implementación operativa.

1.5 Intended Users and Uses

1.5.1 Usuarios del Sistema

Para garantizar que el modelo analítico propuesto genere valor en el contexto operativo de la red de distribución de gas natural en Montería, es fundamental identificar los usuarios que interactuarán con el sistema y comprender cómo utilizarán la información generada. A continuación, se describen los principales usuarios:

1. Área de Operaciones y Atención de Emergencias

Constituye el principal usuario del sistema. Este equipo utilizará el modelo predictivo para anticipar la demanda de emergencias en diferentes zonas y periodos de tiempo, lo que permitirá mejorar la planificación de las cuadrillas, optimizar los tiempos de respuesta y priorizar la asignación de recursos técnicos. Asimismo, podrán identificar zonas con alta frecuencia de eventos, facilitando una gestión más proactiva del servicio.

2. Área de Planeación Operativa

El área de planeación es quizás quien más se beneficia de tener un horizonte de predicción confiable. Hoy toman decisiones de turnos y dimensionamiento con poca información sobre lo que viene; con el modelo, esas decisiones pueden apoyarse en datos reales en lugar de intuición acumulada.

3. Área de Analítica de Datos e Innovación

Será responsable del desarrollo, mantenimiento y mejora continua del modelo predictivo. Este equipo se encargará de actualizar el modelo con nuevos datos, evaluar su desempeño, ajustar parámetros y explorar nuevas técnicas analíticas que permitan incrementar la precisión de las predicciones y el valor del sistema.

4. Nivel Gerencial y Toma de Decisiones Estratégicas

Los directivos y tomadores de decisiones utilizarán los indicadores generados por el sistema para evaluar el desempeño operativo, justificar inversiones en infraestructura o tecnología, y diseñar estrategias orientadas a mejorar la calidad del servicio. El acceso a información basada en datos permitirá fortalecer la toma de decisiones a nivel organizacional.

5. Entidades externas o actores relacionados

Entidades externas como la Comisión de Regulación de Energía y Gas (CREG), aliados estratégicos o interventorías podrán consultar reportes consolidados del sistema para el seguimiento de indicadores operativos, la verificación del cumplimiento normativo y la evaluación del desempeño en la atención de emergencias.

1.5.2 Usos Intencionados del Sistema

El sistema propuesto tiene como finalidad principal apoyar la gestión operativa mediante el uso de analítica de datos y modelos predictivos. A continuación, se describen los usos previstos:

1. Predicción de la demanda de emergencias

El sistema permitirá estimar la cantidad de emergencias esperadas en la red de distribución de gas natural en función del tiempo y la ubicación geográfica, utilizando información histórica y variables relevantes. Esto facilitará la anticipación de eventos y la preparación operativa.

2. Identificación de zonas y periodos críticos

El modelo permitirá detectar patrones espaciales y temporales en la ocurrencia de emergencias, identificando zonas con alta concentración de eventos y periodos de mayor demanda. Esta información será clave para priorizar intervenciones y mejorar la cobertura del servicio.

3. Optimización de la asignación de recursos

A partir de las predicciones generadas, el sistema contribuirá a una distribución más eficiente de los recursos técnicos y humanos, reduciendo tiempos de desplazamiento, evitando sobrecargas operativas y mejorando la capacidad de respuesta ante eventos.

4. Apoyo a la toma de decisiones basada en datos

El modelo funcionará como una herramienta de soporte para la toma de decisiones, proporcionando información cuantitativa y visual que permita evaluar escenarios, analizar tendencias y sustentar decisiones operativas y estratégicas con base en evidencia.

5. Monitoreo y análisis continuo del sistema

Mediante el uso de un dashboard interactivo, los usuarios podrán visualizar en tiempo real indicadores clave, tendencias históricas y predicciones futuras, lo que permitirá realizar un seguimiento continuo del comportamiento de la demanda de emergencias y facilitar una gestión proactiva.

1.6 Assumptions and Limitations

1.6.1 Supuestos

Para el desarrollo y funcionamiento adecuado del modelo analítico propuesto, se establecen los siguientes supuestos, los cuales permiten delimitar el alcance del sistema y garantizar su viabilidad técnica y operativa:

1. Disponibilidad y calidad de los datos

Se asume que los registros históricos de emergencias en la red de distribución de gas natural, junto con variables asociadas como ubicación geográfica, fecha, tipo de evento y variables externas (climáticas o ambientales), se encuentran debidamente almacenados, estructurados y disponibles para su procesamiento. Asimismo, se supone que existe un volumen mínimo de datos históricos suficiente para el entrenamiento de los modelos, aunque se reconoce que pueden requerirse procesos de limpieza, imputación y transformación previos al modelado.

2. Existencia de patrones en la demanda de emergencias

Se supone que la ocurrencia de emergencias no es completamente aleatoria, sino que presenta patrones identificables en el tiempo y el espacio, influenciados por variables operativas, geográficas y ambientales. Este supuesto es fundamental para justificar la aplicabilidad de técnicas de análisis estadístico y aprendizaje automático.

3. Capacidad de modelación mediante técnicas de analítica de datos

Se asume que las relaciones entre las variables de entrada (por ejemplo, condiciones climáticas, ubicación, temporalidad y características operativas) y la variable objetivo (demanda de emergencias) pueden ser capturadas mediante modelos predictivos como algoritmos de machine learning y/o modelos de series de tiempo.

4. Disponibilidad de recursos tecnológicos

Se supone que el entorno de desarrollo cuenta con las herramientas necesarias (lenguaje Python, librerías especializadas y capacidad computacional suficiente) para el procesamiento de datos, entrenamiento de modelos y generación de visualizaciones.

5. Actualización periódica de la información

Se asume que los datos históricos de emergencias y variables asociadas serán actualizados de manera periódica, permitiendo la recalibración del modelo y el mantenimiento de su capacidad predictiva en el tiempo.

6. Apoyo organizacional e integración de áreas

Se supone que las áreas operativas, de planeación y de analítica de datos proporcionarán la información necesaria y participarán en la validación de los resultados del modelo, facilitando su integración dentro de los procesos de toma de decisiones.

1.6.2 Limitaciones

A pesar de su potencial, el modelo propuesto presenta ciertas limitaciones que deben ser consideradas para una adecuada interpretación de sus resultados:

1. Dependencia de la calidad de los datos

El desempeño del modelo predictivo estará directamente condicionado por la calidad, completitud y representatividad de los datos utilizados. La presencia de datos faltantes, inconsistentes o sesgados puede afectar la precisión de las predicciones y limitar la capacidad del modelo para generalizar correctamente.

2. Complejidad en el modelado de fenómenos dinámicos

La demanda de emergencias puede estar influenciada por factores no observados o difíciles de cuantificar (por ejemplo, intervenciones urbanas inesperadas o comportamientos humanos), lo que introduce incertidumbre en las predicciones y limita la capacidad del modelo para capturar completamente la dinámica del sistema.

3. Restricción geográfica y temporal del modelo

El modelo será desarrollado y calibrado inicialmente para la ciudad de Montería, utilizando datos históricos disponibles en un periodo específico. Por lo tanto, su aplicación directa a otras regiones o contextos puede requerir ajustes y procesos adicionales de adaptación.

4. Requerimientos computacionales

El entrenamiento y evaluación de modelos avanzados, especialmente aquellos basados en aprendizaje profundo, pueden demandar tiempos de procesamiento elevados. Para mitigar esta limitación, se priorizará el uso de entornos de ejecución en la nube o plataformas de cómputo colaborativo (como Google Colab), y se evaluará la relación entre complejidad del modelo y ganancia en precisión antes de optar por arquitecturas más demandantes.

La implementación, mantenimiento e interpretación del modelo requieren conocimientos en analítica de datos, estadística y aprendizaje automático. Esto puede limitar su uso directo por parte de usuarios no técnicos sin el apoyo de personal especializado.

6. Interpretabilidad del modelo

Algunos modelos predictivos avanzados pueden presentar dificultades en la interpretación de sus resultados, lo que puede representar un reto al momento de explicar las predicciones y su relación con las variables de entrada en contextos operativos.

1.7 Expected End Product and Deliverables

El presente proyecto tiene como resultado final un sistema analítico integrado compuesto por tres productos técnicos concretos, cada uno directamente vinculado a los objetivos específicos planteados y orientado a transformar la gestión operativa de emergencias en la red de distribución de gas natural en Montería, Córdoba.

1. Modelo predictivo de demanda de emergencias

El producto central del proyecto es un modelo predictivo implementado en Python, entrenado y validado sobre el historial de emergencias de la red de distribución de gas natural. El modelo será capaz de estimar la cantidad de emergencias esperadas por zona geográfica y período de tiempo, identificar períodos y sectores de alta demanda con antelación suficiente para permitir una respuesta proactiva, e incorporar variables

operativas, climáticas, geográficas y temporales como factores explicativos del comportamiento de la demanda. El modelo final corresponderá a la arquitectura con el mejor desempeño con base en los criterios de precisión predictiva, robustez temporal e interpretabilidad descritos en la sección de evaluación de alternativas.

2. Pipeline estructurado de procesamiento de datos

Detrás del modelo hay una infraestructura de datos que lo hace posible. Sin un pipeline que conecte los registros internos de emergencias con variables externas y capas GIS, el modelo simplemente no funciona. Este pipeline (documentado, reproducible y actualizable) es el segundo entregable del proyecto, y en cierta forma el más crítico para que el sistema sobreviva más allá del desarrollo inicial. El pipeline contempla los procesos de extracción, limpieza, imputación, transformación y estructuración de los datos en el formato requerido por cada arquitectura de modelo, garantizando la reproducibilidad del proceso y la capacidad de actualización periódica con nuevos registros operativos.

3. Dashboard interactivo de visualización y soporte a decisiones

El tercer entregable es un dashboard interactivo que traduce los resultados del modelo en información visual directamente accionable para los distintos perfiles de usuario de la organización. El dashboard incluirá: mapas de calor geoespaciales con la distribución esperada de emergencias por zona de Montería, gráficos de tendencias temporales con horizontes de predicción configurables, indicadores de zonas y períodos críticos con niveles de alerta, y visualizaciones del desempeño histórico del modelo mediante las métricas MAE, RMSE y MAPE. La interfaz estará diseñada para ser accesible desde navegador web, con filtros por zona, fecha y tipo de emergencia, permitiendo su uso directo por operadores y planificadores sin requerir conocimientos técnicos en ciencia de datos.

1.8 Background and Literature Survey

La investigación sobre inteligencia artificial aplicada a redes de distribución de gas natural ha avanzado de manera sostenida en las últimas dos décadas, aunque su desarrollo no ha sido uniforme. La mayor parte de los esfuerzos se ha concentrado en dos líneas dominantes: la detección y localización de fugas mediante sensores y procesamiento de señales, y la evaluación de integridad de infraestructura orientada a corrosión, fallas estructurales y riesgos operacionales. Estas dos líneas, aunque técnicamente robustas, dejan fuera un problema igualmente relevante para las operaciones reales de las empresas distribuidoras: saber cuántas emergencias ocurrirán, cuándo y dónde. Es precisamente en esa brecha donde se sitúa el presente proyecto.

Tecnologías de monitoreo y detección temprana

Dentro del ámbito de la detección, tecnologías como el *Distributed Acoustic Sensing* (DAS), el *Ground Penetrating Radar* (GPR) y los sistemas SCADA han transformado la capacidad operativa de los distribuidores de gas. El DAS, por ejemplo, permite convertir tuberías enteras en sensores continuos que capturan vibraciones acústicas a lo largo de kilómetros de red, detectando anomalías en tiempo real sin necesidad de intervención física. El GPR, por su parte, facilita la inspección no invasiva de tuberías subterráneas, identificando discontinuidades estructurales antes de que se conviertan en fallas visibles. Los sistemas SCADA, ya presentes en la mayoría de los operadores de escala media y grande, centralizan la supervisión y el control de variables operativas críticas, constituyendo la columna vertebral del monitoreo en red.

Sobre estas plataformas de datos, los enfoques de *machine learning* y *deep learning* han encontrado terreno fértil. Diversos estudios han demostrado que arquitecturas como las redes neuronales convolucionales (CNN) son capaces de identificar patrones complejos en señales acústicas y de presión asociadas con fugas y comportamientos anómalos, superando en precisión a los métodos de umbral fijo utilizados tradicionalmente. Modelos recurrentes y técnicas híbridas han extendido estas capacidades al dominio temporal, permitiendo detectar no solo el estado actual de la red, sino también anticipar degradaciones progresivas en la infraestructura.

Predicción de demanda: lo que la literatura de otros sectores enseña

La predicción de la demanda de atención —entendida como el pronóstico de cuántos incidentes o emergencias ocurrirán en una zona y período determinados— no es un problema exclusivo del sector del gas. Campos como la salud pública, los servicios de emergencias y las *utilities* en general llevan décadas desarrollando modelos para anticipar la carga operativa y distribuir recursos de manera eficiente. Esta

literatura ofrece una base metodológica valiosa que puede transferirse al contexto de las redes de gas.

Entre los enfoques más consolidados destacan los modelos de series temporales tipo ARIMA (*AutoRegressive Integrated Moving Average*), que permiten capturar tendencias y estacionalidades en datos históricos con relativa parsimonia computacional. Sin embargo, su linealidad los limita cuando las relaciones entre variables son complejas o cuando se incorporan múltiples covariables externas, lo que ha impulsado la adopción de métodos más flexibles.

En ese espacio han ganado protagonismo los algoritmos de aprendizaje automático basados en estructuras de árboles de decisión, y en particular los modelos de *Gradient Boosting* y su variante *Extreme Gradient Boosting* (XGBoost). Propuesto por Chen y Guestrin (2016), XGBoost se ha consolidado como uno de los algoritmos más competitivos en tareas de predicción tabular gracias a su capacidad para manejar relaciones no lineales, tolerar datos heterogéneos, trabajar eficientemente con grandes volúmenes de información y resistir el sobreajuste mediante regularización incorporada. Su adopción en competencias de ciencia de datos y en aplicaciones industriales lo ha convertido en un referente para problemas donde la precisión predictiva y la interpretabilidad son igualmente importantes.

Las *Support Vector Machines* (SVM), introducidas por Cortes y Vapnik (1995), representan otra alternativa relevante para este tipo de problemas. Su fortaleza reside en la capacidad de encontrar hiperplanos de separación óptimos en espacios de alta dimensionalidad, lo que las hace especialmente útiles cuando el conjunto de datos incluye múltiples variables operativas y ambientales que interactúan de formas no evidentes. Aunque computacionalmente más costosas que los métodos basados en árboles para conjuntos de datos grandes, las SVM mantienen vigencia en escenarios con datos moderadamente dimensionales y alta variabilidad.

Arquitecturas profundas para datos secuenciales

Cuando la variable de interés tiene una dependencia temporal explícita —como ocurre con la demanda de emergencias a lo largo del tiempo— las arquitecturas de redes neuronales recurrentes ofrecen ventajas estructurales sobre los métodos anteriores. El modelo *Long Short-Term Memory* (LSTM), propuesto por Hochreiter y Schmidhuber (1997), fue diseñado específicamente para capturar dependencias temporales de largo plazo, superando el problema del desvanecimiento del gradiente que afecta a las redes recurrentes tradicionales. A través de sus compuertas de entrada, olvido y salida, el LSTM aprende selectivamente qué información retener y cuál descartar a lo largo de una secuencia, lo que le permite modelar patrones con ritmos distintos —como ciclos diarios, semanales y estacionales— de forma simultánea.

Complementariamente, las redes recurrentes bidireccionales (*Bidirectional Recurrent Neural Networks*, BRNN), desarrolladas por Schuster y Paliwal (1997), amplían este enfoque procesando las secuencias tanto hacia adelante como hacia atrás en el tiempo. Esto permite al modelo incorporar contexto futuro en la interpretación de cada punto de la serie, lo que mejora el aprendizaje contextual en tareas donde la información de lo que viene después también es informativa, como en la identificación de eventos recurrentes con patrones de anticipación conocidos.

Ambas arquitecturas han demostrado capacidad para integrar covariables exógenas —condiciones climáticas, densidad poblacional, características urbanísticas, festividades o eventos externos— como entradas adicionales al modelo, enriqueciendo la representación del fenómeno más allá de la señal temporal pura.

Optimización de modelos: la capa que cierra el sistema

Más allá del diseño de la arquitectura predictiva, el rendimiento de cualquier modelo de *machine learning* depende en gran medida de la configuración de sus hiperparámetros. La búsqueda de esa configuración óptima en espacios de alta dimensionalidad es, en sí misma, un problema de optimización complejo. En este contexto, las técnicas metaheurísticas han demostrado ser una alternativa eficiente frente a los métodos de búsqueda exhaustiva convencionales.

Entre ellas destaca *Particle Swarm Optimization* (PSO), introducida por Kennedy y Eberhart (1995), que simula el comportamiento colectivo de enjambres de partículas moviéndose a través del espacio de soluciones, guiadas tanto por su propia experiencia como por la mejor solución encontrada por el grupo. Este mecanismo permite explorar de manera eficiente espacios complejos de parámetros sin requerir información sobre la derivada del espacio de búsqueda, lo que la hace aplicable a una amplia variedad de modelos. PSO ha sido empleada exitosamente en ajuste de hiperparámetros, selección de características relevantes y construcción de modelos híbridos que combinan capacidad predictiva con eficiencia computacional.

Brecha identificada y posicionamiento del proyecto

A pesar de la riqueza metodológica descrita, persisten desafíos importantes que la literatura aún no ha resuelto de manera satisfactoria. La disponibilidad y calidad de los datos sigue siendo un cuello de botella frecuente, especialmente en contextos operativos reales donde los registros pueden ser incompletos, inconsistentes o mal estructurados. El desbalance entre clases —cuando los eventos de alta severidad son mucho menos frecuentes que los incidentes menores— introduce sesgos que afectan la

capacidad predictiva de los modelos. Y la generalización de soluciones desarrolladas en contextos geográficos específicos a otras realidades operacionales sigue siendo un reto abierto.

Más importante aún: la mayoría de la investigación existente continúa concentrada en la detección reactiva de fallas físicas mediante sensores, dejando un vacío evidente en el desarrollo de modelos orientados a predecir la demanda de atención operativa — es decir, a responder la pregunta de cuántos recursos humanos y técnicos serán necesarios, y dónde deben estar disponibles, antes de que los eventos ocurran. Esta distinción no es menor: mientras los modelos de detección de fugas actúan sobre la infraestructura física, los modelos de predicción de demanda actúan sobre la capacidad de respuesta organizacional.

Es precisamente en esta intersección —entre las técnicas avanzadas de analítica de datos disponibles y la necesidad operativa no resuelta de los distribuidores de gas en ciudades intermedias— donde el presente proyecto encuentra su justificación técnica y su contribución original.

1.8.1 Marco Contextual: Panorama Internacional y Nacional

La distribución y comercialización de gas natural constituye uno de los pilares energéticos del mundo contemporáneo. Actualmente, más de 4.000 millones de personas dependen de redes de distribución de gas para satisfacer necesidades básicas en sus hogares, industrias y servicios esenciales. Sin embargo, a medida que estas redes se expanden en cobertura y complejidad, también crece un desafío que con frecuencia permanece invisible para el usuario final: la gestión eficiente de emergencias operativas.

Las redes de distribución de gas natural están expuestas de manera permanente a eventos de riesgo como fugas, explosiones, corrosión de tuberías e interrupciones masivas del servicio. Estos incidentes no solo representan pérdidas económicas significativas para los operadores, sino que también pueden comprometer la seguridad de comunidades enteras y afectar la continuidad de servicios esenciales. La magnitud del problema queda evidenciada en cifras concretas: solo en Estados Unidos, la Pipeline and Hazardous Materials Safety Administration (PHMSA) registra anualmente cientos de incidentes en redes de gas natural, muchos de los cuales generan pérdidas millonarias y situaciones de riesgo para las poblaciones aledañas. Entre 2010 y 2023, se reportaron más de 1.500 incidentes significativos en sistemas de distribución de gas en ese país, con costos acumulados que superan los 3.000 millones de dólares en daños directos.

La transición hacia la gestión predictiva: experiencias internacionales

Frente a este panorama, las grandes empresas del sector energético a nivel global han comenzado a transformar su modelo de operación: han pasado de un enfoque

reactivo —en el que los recursos se movilizan una vez ocurrido el evento— hacia un enfoque predictivo, en el que los datos permiten anticipar fallas antes de que se materialicen.

En Europa, países como los Países Bajos y España llevan más de una década liderando esta transición. Operadores como Gasunie (Países Bajos) y Enagás (España) han integrado datos operativos, ambientales y geográficos en plataformas de monitoreo continuo que permiten identificar zonas de riesgo, predecir comportamientos anómalos en la red y priorizar intervenciones de mantenimiento preventivo. El Reino Unido, a través de su operador nacional National Grid, ha implementado sistemas de inteligencia artificial para la detección temprana de fugas y la predicción de fallas en infraestructuras de gas, reduciendo considerablemente los tiempos de respuesta y los costos operativos asociados.

En Alemania, la empresa Open Grid Europe incorpora modelos de simulación y análisis de datos en tiempo real para optimizar la distribución del gas y gestionar contingencias de red, especialmente en contextos de alta variabilidad de la demanda. Estos modelos combinan variables técnicas de la red con datos climáticos y socioeconómicos, lo que permite una visión integral del comportamiento del sistema.

En Asia, el desarrollo ha sido igualmente significativo. China National Petroleum Corporation (CNPC) ha invertido fuertemente en sistemas de monitoreo inteligente de redes que integran sensores IoT, análisis de big data y modelos de aprendizaje automático para predecir y prevenir incidentes en sus extensas redes de distribución. Japón, por su parte, dada su alta exposición a riesgos sísmicos, ha desarrollado sistemas de respuesta automática y modelos predictivos que se activan en función de alertas tempranas, minimizando el impacto de emergencias en la red de gas.

El mensaje que emerge de estas experiencias internacionales es claro y consistente: el futuro de la operación de redes de gas no es reactivo, es predictivo. Las organizaciones que han adoptado modelos analíticos avanzados no solo han mejorado su eficiencia operativa, sino que han logrado reducir la frecuencia e impacto de los eventos de emergencia, protegiendo a sus usuarios y optimizando el uso de sus recursos técnicos y humanos.

El contexto colombiano: avances y brechas pendientes

Colombia no es ajena a este panorama. El país cuenta con una red de distribución de gas natural que abarca más de 30 departamentos y atiende a millones de usuarios residenciales, comerciales e industriales en todo el territorio nacional. Empresas como Surtigas, Gas Natural Fenosa y Vanti operan en diferentes regiones del país, gestionando día a día una amplia variedad de emergencias: desde pequeñas fugas domiciliarias hasta fallas en redes de media y alta presión con impacto en barrios enteros.

A nivel regulatorio, la Comisión de Regulación de Energía y Gas (CREG) establece los marcos normativos para la prestación segura y eficiente del servicio, incluyendo indicadores de calidad y tiempos de atención. Sin embargo, la gestión operativa de emergencias sigue dependiendo en gran medida de enfoques tradicionales basados en la experiencia del personal técnico y en registros históricos de carácter principalmente descriptivo.

Si bien en los últimos años se han registrado avances importantes en digitalización y en el uso de sistemas de información geográfica (SIG) para el mapeo de redes, la incorporación de modelos predictivos de demanda de emergencias aún es limitada en el contexto colombiano. Esta brecha es especialmente notable en ciudades intermedias y mercados regionales, donde la infraestructura de datos y la capacidad analítica de los operadores no alcanzan el nivel de desarrollo que caracteriza a las grandes ciudades o a los operadores de escala nacional.

Es precisamente en este espacio —entre el potencial que ofrecen las herramientas de analítica de datos y la realidad operativa de los distribuidores de gas en ciudades como Montería— donde se sitúa y justifica el presente proyecto.

1.8.2 Marco Teórico

Modelos de Series Temporales: Panorama Histórico

1. Series Temporales Clásicas

Los modelos tradicionales de series temporales han sido ampliamente utilizados en forecasting desde mediados del siglo XX. Los enfoques más prominentes incluyen: ARIMA (AutoRegressive Integrated Moving Average) El modelo ARIMA (p, d, q) representa la clase más general de modelos lineales estacionarios, expresado como:

$$\phi(B)(1 - B)^d X_t = \theta(B)\epsilon_t$$

Donde $\phi(B)$ es el polinomio autorregresivo de orden p , $\theta(B)$ el polinomio de medias móviles de orden q , $(1 - B)^d$ el operador de diferenciación de orden d y $\epsilon_t \sim N(0, \sigma^2)$ ruido blanco.

1.2 SARIMA (Seasonal ARIMA)

Extensión del modelo ARIMA que incorpora componentes estacionales:

$$\phi(B)\Phi(B^s)(1 - B)^d(1 - B^s)^D X_t = \theta(B)\Theta(B^s)\epsilon_t$$

donde s denota el período estacional y los operadores con mayúscula representan componentes estacionales.

Modelos de Suavizamiento Exponencial

La familia de modelos de suavizamiento incluye:

- **Simple Exponential Smoothing (SES):**

$$\hat{y}_{t+1|t} = \alpha y_t + (1 - \alpha)\hat{y}_{t+1|t}$$

- **Holt-Winters:** Incorpora tendencia y estacionalidad mediante componentes aditivos o multiplicativos.

$$L_t = \alpha(Y_t - S_{t-m}) + (1 - \alpha)(L_{t-1} + T_{t-1})$$

1.3 Limitaciones para Mantenimiento Predictivo

Los modelos ARIMA representaron durante décadas el estándar metodológico para el análisis de series temporales, y su solidez estadística los mantiene vigentes en numerosas aplicaciones. Sin embargo, cuando se examina su aplicabilidad al problema específico de predecir la demanda de emergencias en redes de distribución de gas natural, emergen restricciones estructurales que limitan significativamente su capacidad predictiva.

1.4 Asunción de linealidad en un fenómeno inherentemente no lineal

ARIMA modela la variable de interés como una combinación lineal de sus valores pasados y de términos de error anteriores. Esta asunción resulta adecuada para fenómenos con comportamiento estable y relaciones proporcionales entre variables, pero la demanda de emergencias en redes de gas no sigue esa lógica. La ocurrencia de incidentes está determinada por la interacción simultánea de múltiples factores —antigüedad de la infraestructura, condiciones climáticas, presión operativa, densidad urbana, actividad constructiva en la zona— cuyas relaciones son no lineales y dependientes del estado actual del sistema. Un incremento en la temperatura ambiente, por ejemplo, no produce un aumento proporcional y constante en la tasa de emergencias: su efecto varía según la época del año, el tipo de infraestructura expuesta y la historia de mantenimiento de cada segmento de red. ARIMA, por construcción, no puede capturar estas interacciones.

$$\frac{dD}{dt} = f(D, T, P, \omega, \dots)$$

1.5 Naturaleza univariada frente a un problema multivariado

El modelo ARIMA clásico opera sobre una única serie temporal, lo que implica que solo puede aprender del historial de emergencias pasadas sin incorporar información contextual externa. La demanda de emergencias en una red de gas, sin embargo, está condicionada por múltiples variables simultáneas: condiciones meteorológicas, características geográficas y urbanísticas por zona, antigüedad de

la infraestructura por segmento, y variables socioeconómicas de la población atendida, entre otras. Si bien existen extensiones multivariadas como los modelos VAR (*Vector Autoregression*), estas escalan pobremente con la dimensionalidad y mantienen la asunción de linealidad que ya se identificó como problemática. En la práctica, incorporar el conjunto de covariables relevantes para este problema a través de un VAR conduciría a una explosión en el número de parámetros a estimar, generando sobreajuste y una complejidad computacional difícilmente justificable frente a los resultados obtenidos.

$$X_t = \sum_{i=1}^p A_i X_{t-i} + \epsilon_t$$

1.6 Requerimiento de estacionariedad en una serie no estacionaria

ARIMA requiere que la serie temporal sea estacionaria —es decir, que su media y varianza permanezcan constantes a lo largo del tiempo— o que pueda transformarse en estacionaria mediante diferenciación. La demanda de emergencias en redes de distribución de gas no satisface esta condición de manera natural. La serie presenta tendencias de crecimiento asociadas a la expansión de la red y al aumento de usuarios, variaciones estacionales vinculadas a las condiciones climáticas propias de la región Caribe colombiana, y cambios estructurales que reflejan modificaciones en la infraestructura, en los protocolos operativos de la empresa o en las dinámicas urbanas de Montería. Estas no estacionariedades son sistemáticas y significativas, y no desaparecen completamente mediante las transformaciones que ARIMA permite aplicar.

1.7 Incapacidad para capturar dependencias temporales de largo alcance

Los modelos autorregresivos capturan dependencias hasta un rezago p determinado. En el contexto de la demanda de emergencias, esto significa que el modelo solo puede considerar los últimos p períodos como información relevante para la predicción. Sin embargo, los patrones de ocurrencia de emergencias pueden exhibir dependencias de largo plazo que superan ampliamente ese horizonte: un período de lluvias intensas sostenidas puede elevar la tasa de emergencias semanas después, cuando la humedad acumulada en el suelo ha afectado la integridad de segmentos vulnerables de la red. Igualmente, la estacionalidad anual —vinculada a ciclos climáticos en la región— requiere que el modelo recuerde patrones ocurridos hace doce meses para realizar predicciones informadas. Capturar estas dependencias con ARIMA requeriría valores de p muy elevados, lo que introduce nuevamente problemas de sobreajuste y pérdida de parsimonia del modelo.

1.8 Sensibilidad a valores atípicos en datos operativos reales

Los registros históricos de emergencias en entornos operativos reales rara vez son perfectos. Contienen errores de captura, registros duplicados, eventos no reportados, picos transitorios asociados a eventos extraordinarios —como un derrame accidental o una falla masiva por causa externa— y períodos con datos faltantes por interrupciones en los sistemas de información. ARIMA, basado en estimación por mínimos cuadrados, es altamente sensible a estos valores atípicos: un solo evento extremo no representativo puede distorsionar significativamente los coeficientes estimados y degradar la capacidad predictiva del modelo en condiciones normales de operación. Esta fragilidad frente a la imperfección inherente de los datos operativos representa una limitación práctica relevante para su aplicación en el contexto de Surtigas u operadores similares.

1.9 Redes Neuronales Recurrentes

Las Redes Neuronales Recurrentes (RNN) introducen conexiones cíclicas que permiten a la red mantener un “estado oculto” h_t que resume información de pasos temporales anteriores:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t + b_h)$$

$$y_t = W_{hy}h_t + b_y$$

donde x_t es la entrada en tiempo t , h_t el estado oculto, y y_t la salida.

- Problema del Gradiente Desvaneciente

Durante el entrenamiento mediante Backpropagation Through Time (BPTT), el gradiente se propaga hacia atrás multiplicativamente:

$$\frac{\partial \mathcal{L}}{\partial W} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial W} = \sum_{t=1}^T \frac{\partial \mathcal{L}_t}{\partial y_t} \prod_{k=1}^t \frac{\partial h_k}{\partial h_{k-1}}$$

El término $\prod_{k=1}^t \frac{\partial h_k}{\partial h_{k-1}}$ involucra multiplicaciones repetidas de la matriz de pesos W_{hh} .

Si los valores singulares de W_{hh} son:

- < 1 gradientes desvanecen exponencialmente con t

- > 1 gradientes explotan

1.10 XGBoost (Extreme Gradient Boosting)

1.10.1 Motivación y principio de operación

XGBoost, propuesto por Chen y Guestrin (2016), es un algoritmo de aprendizaje supervisado basado en el principio de *boosting*: construye de forma iterativa un ensamble de árboles de decisión, donde cada árbol nuevo se entrena para corregir los errores residuales del ensamble anterior. A diferencia de los métodos de bagging (como Random Forest), que entrenan árboles de forma independiente y paralela, XGBoost los construye secuencialmente, de modo que cada árbol aprende de los errores acumulados por sus predecesores. Esta estrategia, combinada con un esquema de regularización explícita y una aproximación de segundo orden del gradiente, hace de XGBoost uno de los algoritmos más competitivos para tareas de predicción tabular y series temporales con covariables estructuradas — exactamente el tipo de problema que presenta la predicción de demanda de emergencias con variables operativas, climáticas y geográficas.




Figura 1: Diagrama esquemático de arquitectura de red de XGBoost

1.10.2 Formulación del problema de optimización

Dado un conjunto de entrenamiento $\{(x_i, y_i)\}_{i=1}^N$ donde $x_i \in \mathbb{R}^d$ es el vector de features del período i e $y_i \in \mathbb{R}$ es la demanda de emergencias observada, el modelo XGBoost construye una predicción aditiva:

$$\widehat{y}_i^{(M)} = \sum_{m=1}^M f_m(x_i), \quad f_m \in \mathcal{F}$$

donde M es el número total de árboles, f_m es el m -ésimo árbol de decisión y $\mathcal{F}$ es el espacio de funciones de todos los árboles de regresión posibles. La función objetivo que XGBoost minimiza en cada iteración m es:

$$\mathcal{L}^{(m)} = \sum_{i=1}^N l\left(y_i, \widehat{y}_i^{(m-1)} + f_m(x_i)\right) + \Omega(f_m)$$

donde l es la función de pérdida (error cuadrático medio para regresión) y $\Omega(f_m)$ es el término de regularización que penaliza la complejidad del árbol:

$$\Omega(f_m) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

con T el número de hojas del árbol, w_j el peso (valor de predicción) de la hoja j , γ la penalización por número de hojas y λ la penalización L2 sobre los pesos. Este término de regularización es lo que distingue a XGBoost del Gradient Boosting clásico y lo hace significativamente más resistente al sobreajuste.

XGBoost no requiere que los datos estén estructurados como secuencias temporales explícitas — las dependencias temporales se incorporan mediante la construcción manual de variables de rezago ($y_{t-1}, y_{t-2}, \dots, y_{t-p}$ y $y_{t-1}, y_{t-2}, \dots, y_{t-p}$) y features de ventana deslizante (media móvil, desviación estándar en ventanas de k períodos). Esta característica lo hace más interpretable y computacionalmente eficiente, aunque a costa de requerir ingeniería de features más

elaborada y de no capturar dependencias temporales de largo alcance de forma nativa.

1.11 1D-CNN (Red Neuronal Convolucional Unidimensional)

1.11.1 Motivación y principio de operación

Las redes neuronales convolucionales unidimensionales (1D-CNN) fueron originalmente diseñadas para el procesamiento de señales y series temporales, y han demostrado una capacidad sobresaliente para detectar patrones locales en secuencias de datos. A diferencia de las arquitecturas recurrentes, que procesan la secuencia de forma estrictamente temporal paso a paso, las 1D-CNN aplican filtros convolucionales que escanean simultáneamente ventanas de la secuencia, capturando correlaciones locales de forma eficiente y paralelizable. Esta propiedad las hace especialmente adecuadas para identificar patrones de corto plazo en la demanda de emergencias — como picos recurrentes en determinadas horas del día o días de la semana — que pueden no requerir memoria de largo plazo para ser detectados.




Figura 2: Diagrama esquemático de de la red 1D-CNN propuesta empleada para la validación experimental

1.11.2 Operación de convolución

Dada una secuencia de entrada $x \in \mathbb{R}^{T \times d}$ donde T es la longitud temporal y d el número de variables, una capa convolucional 1D aplica F filtros de tamaño k . La salida del f -ésimo filtro en la posición temporal t se calcula como:

$$y_t^{(f)} = \phi \left(\sum_{j=0}^{k-1} w_j^{(f)} \cdot x_{t+j} + b^{(f)} \right)$$

donde $w_j^{(f)} \in \mathbb{R}^{\mathbb{d}}$ son los pesos del filtro f en la posición j , $b^{(f)}$ es el sesgo y $\phi(\cdot)$ es la función de activación (típicamente ReLU): $\phi(z) = \max(0, z)$. El resultado es un mapa de features: $Y \in \mathbb{R}^{(T-k+1) \times F}$ que captura patrones locales de longitud k en la señal.

1.11.3 VAPSO (Velocity-Adaptive Particle Swarm Optimization)

El rendimiento tanto de la 1D-CNN como de la BiLSTM depende críticamente de la configuración de sus hiperparámetros: número de filtros, tamaño del kernel, tasa de aprendizaje, tamaño de batch, número de capas, parámetros de regularización, entre otros. La búsqueda exhaustiva (Grid Search) es computacionalmente inviable en espacios de alta dimensionalidad, mientras que el PSO estándar puede converger prematuramente a óptimos locales. VAPSO es una variante adaptativa de PSO que introduce un mecanismo de ajuste dinámico de la velocidad de las partículas, mejorando el equilibrio entre exploración global y explotación local del espacio de búsqueda.

1.12 Long Short-Term Memory (LSTM)

1.12.1 Arquitectura y Componentes

Las redes LSTM, propuestas por Hochreiter y Schmidhuber (1997), resuelven el problema del gradiente desvaneciente mediante una arquitectura sofisticada basada en compuertas (gates) y un estado de celda C_t que fluye con modificaciones mínimas.




Figura 3: Diagrama esquemático de una celda LSTM

Las ecuaciones que gobiernan una celda LSTM son:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (\text{Forget Gate})$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (\text{Input Gate})$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (\text{Candidate})$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \quad (\text{Cell State})$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (\text{Output Gate})$$

$$h_t = o_t \odot \tanh(C_t) \quad (\text{Hidden State})$$

donde $\sigma(\cdot)$ es la función sigmoide, $\odot$ denota multiplicación elemento a elemento, y $[h_{t-1}, x_t]$ representa concatenación de vectores.

1.12.2 Interpretación de las compuertas

Forget Gate: Decide qué información del estado de celda anterior C_{t-1} debe descartarse. $f_t \in [0,1]^n$ donde valores cercanos a 0 indican "olvido total" y cercanos a 1

"retención completa".

Aplicación al mantenimiento predictivo: En el contexto de la predicción de emergencias en redes de gas, la compuerta de olvido permite descartar fluctuaciones atípicas en la demanda —como un evento puntual de alta afluencia por causa externa— mientras retiene los patrones estacionales y las tendencias de largo plazo que caracterizan el comportamiento histórico de la red.

Input Gate y Candidate: Determinan qué nueva información se incorporará al estado de celda. i_t regula la intensidad mientras $\tilde{C}_t$ propone valores candidatos.

Cell State Update: Combina selectivamente información antigua (modulada por f_t) con nueva información (modulada por i_t).

Output Gate: Filtra el estado de celda para producir el estado oculto h_t que se propaga hacia adelante.

1.12.3 Mitigación del Gradiente Desvaneciente

La clave del éxito de LSTM radica en el flujo del gradiente a través del estado de celda. Durante BPTT:

$$\frac{\partial C_t}{\partial C_{t-1}} = f_t + \text{términos de segundo orden}$$

A diferencia de RNN vanilla donde $\frac{\partial h_t}{\partial h_{t-1}}$ involucra multiplicación por W_{hh} , aquí el gradiente fluye principalmente a través de suma aditiva, evitando el desvanecimiento exponencial. La compuerta forget f_t puede aprender a mantener valores cercanos a 1 para preservar gradientes en dependencias largas.

1.13 Bidirectional LSTM (BiLSTM)

En el contexto de la predicción de demanda de emergencias, donde se dispone del

historial completo de eventos registrados, una BiLSTM puede procesar la secuencia temporal en ambas direcciones para capturar tanto los patrones pasados como el contexto futuro de cada punto de la serie.:

$$\vec{h}_t = \text{LSTM}_{\text{forward}}(x_t, \vec{h}_{t-1})$$

$$\tilde{h}_t = \text{LSTM}_{\text{backward}}(x_t, \tilde{h}_{t+1})$$

$$h_t = [\vec{h}_t; \tilde{h}_t]$$

1.14 Comparación Teórica: Modelos de predicción

Tabla 1: Análisis Comparativo de Modelos de Predicción para Series Temporales Multivariadas

Propiedad	ARIMA	SVM	XGBoost	LSTM	1D-CNN-VAPS O-SVM	BiLSTM
Asume linealidad	Sí	Parcial	No	No	No	No
Manejo de no estacionariedad	Diferenciación	Limitado	Nativo	Nativo	Nativo (CNN)	Nativo
Variables simultáneas (multivariado)	Limitado (VAR)	Sí	Sí	Sí	Sí	Sí (nativo)
Dependencias temporales largas	Limitado (p finito)	No	Parcial (rezagos manuales)	Arbitrariamente largo	Limitado	Arbitrariamente largo
Contexto bidireccional	No	No	No	No	No	Sí (forward + backward)
Extracción automática de features	No	No	Parcial	Sí	Sí (filtros 1D)	Sí (representaciones latentes)
Robustez a outliers	Baja	Media	Alta	Media–Alta	Alta (SVM en salida)	Media–Alta
Escalabilidad con volumen de datos	Media	Baja	Alta	Alta	Media (escala mal con N grande)	Alta
Interpretabilidad	Alta	Media	Media	Baja	Baja (pipeline híbrido)	Baja
Costo computacional	Bajo	Medio	Medio	Alto	Alto (CNN + SVM + VAPS O)	Alto
Requiere estacionariedad	Sí	Sí	No	No	No	No

2 Conceptual Design

El proyecto contempla tres diseños conceptuales principales de modelos predictivos, cada uno basado en una arquitectura distinta: una *Red Neuronal Recurrente Bidireccional con memoria de largo plazo (BiLSTM)* optimizada mediante Particle Swarm Optimization (PSO), un *pipeline híbrido compuesto por una Red Neuronal Convolutacional unidimensional con optimización adaptativa de enjambre de partículas y Máquina de Vectores de Soporte (1D-CNN-VAPSO-SVM)*, y un modelo de *Extreme Gradient Boosting (XGBoost)*. Estos tres enfoques fueron seleccionados por su capacidad de capturar distintos tipos de dependencias temporales y patrones en los registros históricos de emergencias de la red de distribución de gas natural en Montería, Córdoba, cubriendo un espectro que va desde modelos de alta interpretabilidad hasta arquitecturas de aprendizaje profundo de mayor capacidad representacional.


Cada uno de los tres modelos presenta a su vez dos variantes que se diferencian por la cantidad y tipo de variables incluidas en el conjunto de datos utilizado para el entrenamiento:

Variante 1 — Variables base: El modelo se entrena con un conjunto de variables operativas y temporales directamente relacionadas con el comportamiento histórico de las emergencias en la red. Estas incluyen: fecha y hora del evento, tipo de emergencia (fuga, interrupción, falla de presión, entre otras), ubicación geográfica (zona o sector de Montería), cantidad de emergencias registradas por período y variables de la red como tipo de infraestructura y nivel de presión operativa. Esta configuración permite al modelo aprender los patrones fundamentales de la demanda de emergencias — tendencias, ciclos semanales y estacionalidades — a partir de la señal histórica pura.

Variante 2 — Variables enriquecidas: Amplía la configuración anterior incorporando variables contextuales que aportan una visión más completa del entorno físico, ambiental y urbanístico. Entre estas se incluyen: condiciones climáticas (temperatura, humedad relativa, precipitación y presión atmosférica), características geográficas y de suelo (litología, tipo de terreno, zonas de relleno urbano), variables socioeconómicas y urbanas (densidad poblacional por sector, actividad constructiva en la zona, antigüedad estimada de la infraestructura por segmento) y datos espaciales provenientes de sistemas de información geográfica (GIS). Esta configuración permite al modelo relacionar el entorno físico y operativo con la ocurrencia de emergencias, incrementando potencialmente la precisión predictiva en zonas con características particulares.

En conjunto, se dispone de seis modelos conceptuales (tres arquitecturas × dos configuraciones de variables), los cuales serán entrenados, validados y comparados entre sí mediante métricas cuantitativas de desempeño (MAE, RMSE y MAPE). El objetivo de esta evaluación comparativa es seleccionar la configuración que mejor equilibre precisión predictiva, capacidad de generalización y viabilidad computacional para su implementación en el contexto operativo de la empresa distribuidora.

Figura 4: Diagrama de flujo del método propuesto para predicción de emergencias mediante BiLSTM.



- Consideraciones de Seguridad y Criterios de Evaluación Operativa

Dado que el sistema propuesto está orientado a apoyar la gestión de emergencias en infraestructura crítica de distribución de gas natural, la evaluación del modelo no puede limitarse a métricas de error promedio. En este contexto, los errores de predicción no tienen consecuencias simétricas: subestimar la demanda de emergencias en una zona y período determinados puede traducirse en una asignación insuficiente de cuadrillas, tiempos de respuesta prolongados y riesgo directo para la seguridad de los usuarios y la continuidad del servicio. Por esta razón, se establecen las siguientes consideraciones que deben orientar tanto la selección del modelo como la interpretación de sus resultados.

1. Priorización del Recall sobre la Precisión

En el contexto de clasificación de niveles de demanda (baja, media, alta), se priorizará el Recall sobre la Precisión como métrica de referencia para la evaluación del modelo. Esta decisión responde a una asimetría operativa fundamental: un falso positivo —predecir alta demanda cuando en realidad la demanda será moderada— genera como consecuencia un despliegue preventivo de recursos que, aunque innecesario, no compromete la seguridad del servicio. Un falso negativo —predecir demanda baja cuando en realidad se producirá un pico de emergencias— puede resultar en una respuesta operativa insuficiente con consecuencias directas sobre la seguridad de las comunidades atendidas y el cumplimiento de los indicadores regulatorios establecidos por la CREG. Por lo tanto, se acepta un nivel controlado de sobrepredicción a cambio de minimizar la probabilidad de subestimar períodos de alta demanda.

2. Validación sobre períodos no observados

La evaluación final del modelo se realizará sobre períodos históricos completamente excluidos del proceso de entrenamiento y ajuste de hiperparámetros, siguiendo el esquema walk-forward descrito en la sección de metodología de validación. Esto garantiza que las métricas reportadas reflejen el desempeño real del modelo ante datos genuinamente nuevos, sin contaminación por información futura. En particular, se prestará especial atención al comportamiento del modelo durante períodos de alta variabilidad que representan precisamente los escenarios donde la planificación operativa es más crítica y donde un modelo sobreajustado a condiciones históricas típicas puede fallar de forma sistemática.

3. Interpretabilidad parcial orientada al operador

Si bien las arquitecturas de aprendizaje profundo como BiLSTM presentan limitaciones inherentes de interpretabilidad, el sistema incorporará mecanismos de análisis de importancia de variables que permitan a los operadores y planificadores entender los factores que impulsan cada predicción. Para BiLSTM y 1D-CNN-VAPSO-SVM se explorarán técnicas de saliency maps y análisis de atención que identifiquen qué pasos temporales y qué variables tienen mayor influencia en la predicción generada. Para XGBoost, se utilizarán valores SHAP que descompongan cada predicción en la contribución individual de cada variable, ofreciendo explicaciones directamente comprensibles para usuarios no técnicos. Esta interpretabilidad parcial es esencial para que el sistema sea adoptado con confianza por los equipos operativos, quienes necesitan no solo conocer la predicción sino también poder validar su coherencia con su experiencia en campo.

2.2 Evaluation of Design Alternatives

2.2.2 XGBoost

- Preprocesamiento

Antes de alimentar el modelo, los datos históricos de emergencias deben atravesar un pipeline de preparación estructurado. Los valores faltantes se imputan mediante métodos estadísticos (media o mediana para variables simétricas) o mediante el algoritmo k-Nearest Neighbors (kNN) cuando el patrón de ausencia tiene dependencia espacial o temporal, ya que este método preserva mejor la estructura local de los datos. Las variables categóricas —como el tipo de emergencia, la zona geográfica o el tipo de infraestructura— se codifican mediante target encoding cuando presentan alta cardinalidad (más de 10 categorías distintas), y mediante one-hot encoding cuando su cardinalidad es moderada. A diferencia de las redes neuronales, XGBoost no requiere escalado de variables numéricas por su naturaleza basada en particiones de árboles, lo que simplifica este paso del pipeline.

- División temporal de los datos

Dado que la demanda de emergencias es una variable con dependencia temporal estructural, la división de los datos debe respetar estrictamente el orden cronológico para evitar lo que en la literatura se conoce como data leakage — la contaminación del conjunto de prueba con información del futuro. Se propone el siguiente esquema:

- **Entrenamiento:** 70% inicial del período histórico disponible (por ejemplo, desde el primer registro hasta el corte t_0)
- **Validación:** 15% siguiente, evaluado mediante time-series cross-validation con ventana deslizante (expanding window), donde el modelo se reentrena progresivamente incorporando nuevos datos y se evalúa siempre sobre el período inmediatamente posterior
- **Prueba final:** 15% restante, correspondiente al período más reciente, utilizado una única vez para reportar el desempeño final del modelo sin intervención en las decisiones de ajuste

Esta estrategia de validación walk-forward es especialmente relevante para el contexto del proyecto, ya que permite estimar cómo se comportará el modelo cuando se despliegue en producción enfrentando datos genuinamente nuevos.

- Ajuste de hiperparámetros

Los principales hiperparámetros de XGBoost que determinan su capacidad y comportamiento son: la tasa de aprendizaje (`learning_rate`), el número de árboles

(`n_estimators`), la profundidad máxima de cada árbol (`max_depth`), la fracción de muestras usadas por árbol (`subsample`), la fracción de columnas por árbol (`colsample_bytree`) y los coeficientes de regularización L1 y L2 (`reg_alpha` y `reg_lambda` respectivamente). Su búsqueda óptima se realizará mediante optimización bayesiana o búsqueda aleatoria (random search) con validación cruzada temporal, priorizando la estabilidad del error en el esquema walk-forward sobre el ajuste en un único fold.

- Métricas de evaluación

Para la tarea de predicción de conteos de emergencias (regresión), las métricas principales serán el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE), dado que penalizan de forma diferenciada los errores pequeños y los picos de predicción. Si el problema se reformula como clasificación de niveles de demanda (baja, media, alta), se complementará con Accuracy, F1-score ponderado y la curva ROC/PR para evaluar el comportamiento en clases desbalanceadas.

- Regularización y control del sobreajuste

Se implementará early stopping sobre el conjunto de validación temporal: el entrenamiento se detiene automáticamente cuando el error de validación deja de mejorar tras un número definido de iteraciones consecutivas (patience). Esto previene el sobreajuste a picos históricos que no se repetirán en el futuro. El ajuste de `reg_alpha` y `reg_lambda` añade penalización explícita sobre la complejidad del modelo, complementando el early stopping.

- Interpretabilidad y uso operativo

Una ventaja distintiva de XGBoost frente a las arquitecturas profundas es su mayor interpretabilidad, que puede potenciarse mediante el uso de valores SHAP (SHapley Additive exPlanations). Los valores SHAP permiten descomponer cada predicción individual en la contribución de cada variable de entrada, ofreciendo tanto una perspectiva global (qué variables son más importantes en promedio para el modelo) como una perspectiva local (qué factores específicos explican la predicción de un día o zona particular). En el contexto operativo, esto significa que un planificador podría entender, por ejemplo, que la predicción de alta demanda para el próximo martes se explica principalmente por la combinación de lluvia acumulada, actividad constructiva en la zona norte y baja disponibilidad histórica de cuadrillas en ese día de la semana — información directamente accionable para la toma de decisiones. En producción, el modelo se exporta como un objeto serializado (booster) que recibe como entrada una ventana de variables actuales y genera el pronóstico para el horizonte requerido, integrándose con el pipeline ETL de la empresa para cálculos diarios y generación de alertas de demanda alta.

2.3 BiLSTM (Red Neuronal Recurrente Bidireccional con Memoria de Largo Plazo) Estructura de entrada

La BiLSTM recibe como entrada secuencias temporales estructuradas como tensores tridimensionales de la forma $(B \times L \times d)$, donde B es el tamaño del batch, L es la longitud de la ventana temporal y d es el número de variables en cada paso de tiempo. Se propone una ventana de longitud $L = 168$ pasos (equivalente a una semana en resolución horaria), que captura ciclos diarios y semanales completos. El vector de características por paso temporal incluye: conteo de reportes de emergencias, variables climáticas (temperatura, humedad, precipitación), disponibilidad de cuadrillas técnicas, indicadores de eventos urbanos en la zona, y codificaciones cíclicas de variables temporales como el día de la semana y la hora del día mediante transformaciones seno-coseno:

$$\text{hora seno} = \sin\left(\frac{2\pi}{24} \cdot h\right), \text{hora coseno} = \cos\left(\frac{2\pi}{24} \cdot h\right)$$

Esta codificación preserva la continuidad circular del tiempo, evitando que el modelo interprete la transición entre la hora 23 y la hora 0 como un salto discontinuo. Si el modelo se extiende a múltiples zonas de Montería, se puede incorporar un embedding de zona como entrada adicional o modelar cada zona de forma independiente con pesos compartidos.

- Arquitectura propuesta

El flujo de procesamiento sigue la siguiente secuencia:

1. **Capa de entrada:** Tensor $(B \times L \times d)$ con las secuencias temporales normalizadas
2. **Capa 1D-CNN opcional (preprocesamiento):** Una o dos capas convolucionales de preprocesamiento para extraer patrones locales de corto plazo antes de la capa recurrente, reduciendo el ruido de alta frecuencia y facilitando el aprendizaje de la BiLSTM
3. **Capas BiLSTM (1–2 capas):** Entre 64 y 256 unidades ocultas por dirección, según la complejidad del patrón identificado durante la exploración. La salida de la última capa BiLSTM puede ser la representación del último paso temporal o el promedio sobre todos los pasos (global average pooling)
4. **Capa densa de salida:** Una neurona con activación lineal para regresión de conteos, o tantas neuronas como clases con activación softmax para clasificación de niveles de demanda
5. Regularización: Dropout entre capas LSTM ($p_d = 0.2-0.4$) y recurrent dropout dentro

de las celdas para controlar el sobreajuste en las conexiones recurrentes

- **Entrenamiento**

El entrenamiento se realiza con el optimizador Adam con programación adaptativa de la tasa de aprendizaje (learning rate scheduling), usando la función de pérdida MSE para regresión o entropía cruzada para clasificación. Los minibatches se construyen como secuencias temporales contiguas, respetando estrictamente el orden cronológico para evitar que datos del futuro contaminen el entrenamiento. Se implementa early stopping con monitoreo de la pérdida de validación y se mantiene el mejor modelo observado durante el entrenamiento (model checkpoint).

- **Validación walk-forward**

La evaluación del modelo sigue una estrategia de rolling-origin evaluation: se entrena con el intervalo $[t_0, t_1]$, se valida sobre $[t_1 + 1, t_2]$, se expande la ventana de entrenamiento incorporando el período validado, y se repite el proceso. Esta metodología estima de forma realista la estabilidad del modelo frente a cambios estacionales derivados de distribución y eventos atípicos, y es el estándar metodológico recomendado para series temporales con dependencia no estacionaria.

2.4 1D-CNN-VAPSO-SVM

- **Flujo de procesamiento**

El pipeline híbrido opera en tres etapas secuenciales bien diferenciadas:

Extracción de características (1D-CNN): Las secuencias temporales por zona pasan por múltiples capas convolucionales con filtros de distintos tamaños de kernel, capturando simultáneamente patrones de corto plazo (picos diarios, transiciones abruptas) y de mediano plazo (tendencias semanales). La salida de la CNN es un vector de embeddings temporales compacto por ventana, que representa la secuencia de forma densa en un espacio de menor dimensionalidad.

Optimización de hiperparámetros (VAPSO): VAPSO optimiza de forma conjunta los hiperparámetros de la CNN (número de filtros, tamaño de kernel, configuración de pooling) y los parámetros del SVM (kernel, coeficiente de regularización CC

C y parámetro γ . La búsqueda se realiza sobre conjuntos de validación temporal con esquema *walk-forward*, garantizando que la optimización no incurra en lookahead sobre datos futuros.

Predicción final (SVM): El vector de embeddings generado por la CNN alimenta el SVM, que realiza la regresión de conteos o la clasificación de niveles de demanda. El SVM opera en el espacio de características transformado, donde los patrones temporales ya han sido

extraídos por la CNN, simplificando la tarea de decisión final.

- **Ventajas operativas**

La separación explícita entre extracción de características (CNN) y decisión final (SVM) ofrece una ventaja interpretativa parcial respecto a las arquitecturas puramente profundas: es posible analizar los filtros aprendidos por la CNN para identificar qué patrones temporales activa con mayor intensidad, y la frontera de decisión del SVM en el espacio de embeddings es conceptualmente más transparente que la de una red profunda de múltiples capas. VAPSO permite una búsqueda eficiente en espacios continuos y discretos de hiperparámetros sin requerir el cálculo de gradientes del espacio de búsqueda, siendo robusto frente a funciones objetivo no diferenciables o con múltiples óptimos locales.

- **Limitaciones a considerar**

La integración de tres componentes (CNN + VAPSO + SVM) introduce complejidad de implementación y mantenimiento superior a los modelos individuales. La sensibilidad a la configuración inicial de VAPSO (tamaño del enjambre, coeficientes de aceleración) puede influir en la convergencia, y el costo computacional del proceso de optimización puede ser significativo cuando el espacio de búsqueda es amplio. Estas consideraciones deben evaluarse frente a la ganancia en precisión predictiva durante la fase de comparación experimental.

2.5 Evaluación y selección de alternativas

Criterios de decisión

La selección del modelo definitivo para implementación se realizará con base en los siguientes criterios técnicos y operativos, ponderados según su relevancia para el contexto de Surtigas en Montería:

Tabla 2: Criterios de Evaluación y Selección de Modelos Predictivos

Criterio	Descripción	Peso
Precisión predictiva	MAE y RMSE para regresión; F1 y Recall para clasificación	35%
Robustez temporal	Estabilidad del error en validación walk-forward ante cambios estacionales	25%
Interpretabilidad	Capacidad de explicar predicciones a operadores no técnicos (SHAP, importancia de variables)	20%
Costo computacional	Tiempo de entrenamiento,	15%

	latencia de inferencia y recursos requeridos	
Facilidad de integración	Capacidad de serializar el modelo y servirlo en un pipeline ETL o API	10%

Si la prioridad es la rapidez de despliegue y la interpretabilidad para los operadores, **XGBoost** actúa como línea base operacional sólida. Su menor costo computacional, su capacidad de generar explicaciones mediante SHAP y su robustez frente a datos heterogéneos e incompletos lo convierten en el candidato más viable para una primera implementación funcional. Puede entrar en producción con menor infraestructura y menor tiempo de desarrollo, ofreciendo valor operativo desde etapas tempranas del proyecto.

Cuando el volumen de series por zona es suficiente y la dependencia temporal es el factor dominante del comportamiento de la demanda, **BiLSTM** ofrece ventajas estructurales que XGBoost no puede replicar de forma nativa: la captura de dependencias de largo plazo, el contexto bidireccional y la integración natural de covariables exógenas en la secuencia. Es el modelo con mayor potencial de precisión para horizontes de predicción más amplios y patrones estacionales complejos.

Finalmente, si se dispone de capacidad computacional suficiente y se busca maximizar la extracción automática de patrones sin ingeniería manual de features, **1D-CNN-VAPSO-SVM** representa el enfoque de mayor complejidad arquitectónica, con potencial de alto rendimiento especialmente en la clasificación de niveles de demanda por zona.

La selección definitiva se realizará de forma empírica una vez ejecutados los experimentos comparativos, tomando como referencia principal el desempeño en el conjunto de prueba con esquema walk-forward y el criterio ponderado descrito en la tabla anterior.

2.6 Plan de Acción Preliminar (Cronograma base)

Con base en los diseños conceptuales desarrollados y los entregables definidos, se establece el siguiente cronograma base que estructura las actividades previstas para la fase de implementación. Las actividades se organizan en cinco fases secuenciales con dependencias explícitas entre ellas.

Fase 1 — Recolección, integración y auditoría de datos (Semanas 1–3)

Recopilación y consolidación del historial completo de emergencias de los sistemas internos de la empresa, integración con fuentes externas de variables climáticas y datos

GIS, auditoría de calidad de los datos (identificación de valores faltantes, inconsistencias, duplicados y sesgos de registro), y documentación del inventario de variables disponibles para cada variante de modelo.

Fase 2 — Preprocesamiento y construcción del pipeline de datos (Semanas 3–5)

Implementación del pipeline de limpieza, imputación y transformación de datos, construcción de las variables de ingeniería de features (rezagos temporales, medias móviles, codificaciones cíclicas, encodings de variables categóricas), estructuración de los conjuntos de entrenamiento, validación y prueba con esquema walk-forward, y validación del pipeline sobre el conjunto de datos completo.

Fase 3 — Entrenamiento y evaluación de modelos (Semanas 5–10)

Implementación y entrenamiento de las tres arquitecturas propuestas (BiLSTM, 1D-CNN-VAPSO-SVM y XGBoost) en sus dos variantes de variables cada una, optimización de hiperparámetros mediante PSO/VAPSO y búsqueda bayesiana según corresponda, evaluación comparativa con métricas MAE, RMSE, MAPE, F1 y Recall en el esquema walk-forward, y selección formal del modelo definitivo con base en los criterios ponderados definidos en la sección de evaluación de alternativas.

Fase 4 — Construcción del dashboard interactivo (Semanas 9–12)

Diseño y desarrollo del dashboard de visualización con los módulos de mapas de calor geoespaciales, tendencias temporales, alertas de demanda y métricas de desempeño del modelo, integración del modelo seleccionado como motor de predicción del dashboard, y pruebas de usabilidad con usuarios representativos de las áreas de operaciones y planeación.

Fase 5 — Validación operativa, documentación y cierre (Semanas 12–14)

Validación del sistema completo en condiciones operativas reales con datos recientes, documentación técnica del modelo, el pipeline y el dashboard, elaboración del informe final de resultados con análisis de impacto operativo estimado, y presentación de conclusiones y recomendaciones para la implementación definitiva en la empresa distribuidora.

Tabla 3: Cronograma base para proyecto II

Fase	Actividad principal	Mes/periodo	Entregable asociado
1	Recolección y	Junio - 2026	Inventario de

	auditoría de datos		variables y reporte de calidad
2	Preprocesamiento y pipeline	Junio - Julio / 2026	Pipeline documentado e implementado
3	Entrenamiento y evaluación de modelos	Agosto - septiembre / 2026	Modelo seleccionado + reporte comparativo
4	Dashboard interactivo	Septiembre - Octubre / 2026	Dashboard funcional integrado al modelo
5	Validación, documentación y cierre	Noviembre - 2026	Informe final + presentación de resultados

References

- J. Lian, Y. Zhang, C. Ma, Y. Yang, and E. Chaima, "A review on recent sizing methodologies of hybrid renewable energy systems," *Energy Conversion and Management*, vol. 199, p. 112027, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0196890419310337>
- Aibar, S., González-Blas, C. B., Moerman, T., Huynh-Thu, V. A., Imrichova, H., Hulselmans, G., Rambow, F., Marine, J., Geurts, P., Aerts, J., Van Den Oord, J., Atak, Z. K., Wouters, J., & Aerts, S. (2017). SCENIC: single-cell regulatory network inference and clustering. *Nature Methods*, 14(11), 1083-1086. <https://doi.org/10.1038/nmeth.4463>
- J. Lian, Y. Zhang, C. Ma, Y. Yang, and E. Chaima, "A review on recent sizing methodologies of hybrid renewable energy systems," *Energy Conversion and Management*, vol. 199, p. 112027, 2019. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0196890419310337>
- Schuster, M., & Paliwal, K.K. (1997). Bidirectional recurrent neural networks. *IEEE Trans. Signal Processing*.
- Awuku, S., et al. (2024). Integración de datos climáticos e incidentes para la predicción de daños en ductos. *Revista de Integridad de Tuberías*, 15(2), 123–142.
- Barton, J., et al. (2022). Predicción fiable de la probabilidad de fallo de oleoductos mediante árboles de potenciación de gradiente. *Revista Internacional de Ingeniería de Oleoductos*, 11(1), 55–68.
- C -FER Technologies. (2019). Identificación de modos de falla y evaluación de riesgos de excavaciones de tuberías. Informe técnico.
- Fares, T., & Zayed, T. (2010). Sistema experto jerárquico difuso para la evaluación del riesgo de fallas en tuberías de agua. *Expert Systems with Applications*, 37(12), 8519–8529.
- Hong, Y., et al. (2023). Análisis de riesgo basado en redes bayesianas dinámicas de daños causados por terceros en gasoductos. *Reliability Engineering & System Safety*, 225, 108650. Latifi, F., et al. (2024). Revisión exhaustiva de métodos de aprendizaje automático basados en árboles para la predicción de fallas en tuberías. *Engineering Failure Analysis*, 146, 106841.

- Mahjoob, H., et al. (2024). Análisis espacial para la evaluación de la vulnerabilidad de los gasoductos utilizando SIG y AHP. *Safety Science*, 156, 105942.
- OptaSense. (2025). Detección acústica distribuida para la detección de intrusiones en tuberías. Informe de la industria.
- Oreste, M. L., et al. (2019). Inspección en línea sin contacto y en tiempo real para la detección de corrosión interna en tuberías mediante matrices de sensores ópticos. *Sensors and Actuators A: Physical*, 289, 182–191.