
Analisis exploratorio de Emergencias en la Red de Distribución de Gas Natural de Montería

Proyecto de Grado — Ingeniería Industrial
Universidad Tecnológica de Bolívar

Autores

Ángel Luis Vega Rodríguez
Germán Eduardo De Armas Castaño
Sebastián Enrique Delgado Solano
Victoria Ripoll

Índice

1. Introducción	2
2. Estructura del Dataset	2
2.1. Columnas disponibles	2
2.2. Observaciones generales del dataset	3
3. Clasificación de Variables	3
3.1. Variables directamente utilizables	3
3.1.1. Variables operativas directas	3
3.1.2. Variables espaciales	4
3.2. Variables que requieren transformación	4
3.2.1. Columnas de fechas — conversión y extracción	4
3.2.2. Causal solicitud — estandarización de categorías	5
3.3. Variables derivadas a construir	5
3.3.1. Variable objetivo principal	5
3.3.2. Features de rezago y ventana deslizante	6
3.3.3. Features de texto libre (opcional — NLP básico)	6
3.4. Variables a excluir del modelo	6
4. Variables Externas a Integrar	7
5. Resumen del Pipeline de Features	9
5.1. Variante 1 — Variables base (solo fuentes internas)	9
5.2. Variante 2 — Variables enriquecidas (fuentes internas + externas)	9

1. Introducción

El presente documento describe el análisis exploratorio del archivo `Historico_Emergencias_Montería` fuente de datos interna provista por Surtigas para el desarrollo del modelo analítico predictivo de demanda de emergencias en la red de distribución de gas natural de Montería, Córdoba.

El objetivo de este análisis es identificar, clasificar y documentar las variables disponibles en el dataset, determinar cuáles serán incorporadas en el modelo predictivo y en qué forma, y establecer las transformaciones necesarias para convertir los datos operativos crudos en features de aprendizaje automático.

El dataset contiene registros de órdenes de emergencia atendidas por Surtigas desde el año 2017, con información operativa, temporal, espacial y descriptiva de cada incidente. Cada fila representa una orden de trabajo individual, identificada por un número de orden y asociada a un contrato de usuario.

2. Estructura del Dataset

2.1. Columnas disponibles

El archivo contiene las siguientes columnas en su única hoja (Hoja1):

Columna	Descripción
Fecha registro orden	Timestamp de registro de la emergencia (valor numérico Excel)
Año	Año de la emergencia
Tipo de Emergencia	Clasificación: <i>Controlada</i> / <i>No Controlada</i>
Ase_Asne	Clasificación interna del tipo de atención
Dpto_SSPD	Código de departamento (siempre 23 = Córdoba)
Descripción del departamento	Siempre "CORDOBA"
Loca_SSPD	Código de localidad (siempre 1 = Montería)
Descripción de la localidad	Siempre "MONTERIA"
Orden	Número único de la orden de trabajo
Contrato	Número de contrato del usuario afectado
Dirección	Dirección del incidente
Cod Tipo Trabajo	Código del tipo de intervención realizada
Desc Tipo Trabajo	Descripción textual del tipo de trabajo
Codigo unidad operativa	Código de la cuadrilla asignada
Nombre unidad operativa	Nombre del técnico o cuadrilla responsable
Cod Estado Orden	Código del estado final de la orden

Columna	Descripción
Desc estado de la orden	Estado final: <i>Cerrada, Abierta</i> , etc.
Fecha asignación	Timestamp de asignación al técnico
Fecha_llegada	Timestamp de llegada al sitio
Fecha_control	Timestamp de control del incidente
Fecha_normalizacion	Timestamp de normalización del servicio
Fecha_finalizacion	Timestamp de cierre definitivo
Contacto	Identificación del usuario contactado
Persona ejecuta	Técnico que ejecutó la orden
Persona legaliza	Técnico que legalizó el cierre
Nro_solicitud	Número interno de la solicitud asociada
Fecha solicitud	Timestamp de la solicitud
Persona genera solicitud	Usuario del sistema que generó la solicitud
Interaccion	Código de interacción
Causal solicitud	Naturaleza del incidente (código + descripción textual)
Observacion solicitud	Texto libre de la llamada entrante
Observación	Texto libre del técnico sobre el hallazgo en campo

2.2. Observaciones generales del dataset

- Las fechas están almacenadas en formato numérico de Excel y deben convertirse a `datetime` antes de cualquier análisis.
- Las columnas `Dpto_SSPD`, `Loca_SSPD`, `Descripción del departamento` y `Descripción de la localidad` son constantes para todo el dataset y no aportan señal predictiva.
- La columna `Causal solicitud` contiene la información más valiosa sobre el tipo de emergencia y requiere estandarización.
- Las columnas `Observacion solicitud` y `Observación` contienen texto libre con información contextual relevante que puede explotarse mediante técnicas de NLP.

3. Clasificación de Variables

Las variables se clasifican en cuatro categorías según su rol en el pipeline del modelo predictivo: variables directamente utilizables, variables que requieren transformación, variables derivadas a construir, y variables a excluir.

3.1. Variables directamente utilizables

3.1.1. Variables operativas directas

Columna	Tipo	Uso en el modelo
Tipo de Emergencia	Categórica binaria	Variable objetivo auxiliar: <i>Controlada</i> vs. <i>No Controlada</i>
Cod Tipo Trabajo	Numérico categórico	Tipo de intervención requerida; proxy de severidad del incidente
Desc Tipo Trabajo	Categórica textual	Versión legible de Cod Tipo Trabajo
Nombre unidad operativa	Categórica	Cuadrilla asignada; útil para modelar disponibilidad operativa
Desc estado de la orden	Categórica	Filtro de calidad: entrenar solo con órdenes en estado <i>Cerrada</i>

3.1.2. Variables espaciales

Columna	Tipo	Uso en el modelo
Dirección	Texto libre	Geocodificación para asignar barrio/zona; unidad espacial del modelo

La columna **Dirección** es la fuente primaria de información espacial. Su procesamiento requiere geocodificación mediante la API de Google Maps o Nominatim, o alternativamente, extracción de barrio mediante expresiones regulares sobre los patrones de dirección registrados (p. ej., “B MOGAMBO MZ 58 LT 5” → barrio: Mogambo).

3.2. Variables que requieren transformación

3.2.1. Columnas de fechas — conversión y extracción

El dataset contiene seis timestamps almacenados como números decimales en formato Excel. Cada uno debe convertirse a `datetime` y de ellos se extraen las features temporales del modelo.

Columna original	Variables derivadas
Fecha registro orden	hora_registro, dia_semana, mes, semana_anio, anio, es_fin_semana, es_festivo, hora_seno = $\sin\left(\frac{2\pi h}{24}\right)$, hora_coseno = $\cos\left(\frac{2\pi h}{24}\right)$
Fecha asignación & Fecha_llegada	tiempo_respuesta = $t_{\text{llegada}} - t_{\text{asignación}}$ (minutos)
Fecha_llegada & Fecha_control	tiempo_control = $t_{\text{control}} - t_{\text{llegada}}$ (minutos)
Fecha registro orden & Fecha_finalizacion	duracion_total = $t_{\text{fin}} - t_{\text{registro}}$ (minutos)

Nota sobre la codificación cíclica del tiempo. La hora del día y el día de la semana son variables cíclicas: la hora 23 es más cercana a la hora 0 que a la hora 12. Una codificación lineal estándar no captura esta continuidad. La transformación seno-coseno resuelve este problema:

$$h_{\sin} = \sin\left(\frac{2\pi \cdot h}{24}\right), \quad h_{\cos} = \cos\left(\frac{2\pi \cdot h}{24}\right) \quad (1)$$

De forma análoga para el día de la semana ($T = 7$) y el mes del año ($T = 12$).

3.2.2. Causal solicitud — estandarización de categorías

Esta columna contiene cadenas con el formato <código><tipo_C_o_NC>- <descripción>, por ejemplo:

```
289 C - AUSENCIA DE GAS
61 NC - ESCAPE EN LA RED INTERNA
54 - DANO DE TUBERIA
55 - OLOR A GAS
297 C - ROBO DE MEDIDOR
58 NC - AUSENCIA DE GAS (MASIVA)
53 - EXPLOSION
298 NC - INCENDIO EN INMUEBLE
```

Se propone crear una variable categórica limpia `tipo_incidente` con las siguientes clases consolidadas:

Clase	Causales incluidas
AUSENCIA_GAS	289 C, 58 NC — ausencia individual y masiva
ESCAPE_INTERNO	291 C, 61 NC — fugas en red interna del predio
ESCAPE_MEDICION	292 C, 60 NC — fugas en centro de medición / regulador
ESCAPE_RED_EXT	55, 54 — olor a gas y daño de tubería en red externa
BAJA_PRESION	296 C — baja presión en el servicio
ALTA_PRESION	331 C — alta presión / consumo elevado
ROBO_MEDIDOR	297 C — hurto de centro de medición
INCENDIO_EXPLOSION	298 NC, 53 — incendio en inmueble y explosión
OTROS	Causales no clasificadas en las anteriores

3.3. Variables derivadas a construir

Estas variables no existen en el dataset original pero se construyen como parte del pipeline de ingeniería de features.

3.3.1. Variable objetivo principal

La variable que el modelo debe predecir es el conteo de emergencias por zona y período:

$$Y_{z,t} = \sum_i \mathbf{1}[\text{zona}(i) = z \wedge \text{periodo}(i) = t] \quad (2)$$

donde z es la zona geográfica (barrio de Montería) y t es el período temporal de análisis (diario, semanal o mensual según el horizonte de predicción elegido).

3.3.2. Features de rezago y ventana deslizante

Para capturar la autocorrelación temporal de la demanda, se construyen las siguientes features de rezago sobre $Y_{z,t}$:

Variable	Definición
lag_1, lag_7, lag_30	Demanda en el período $t - 1$, $t - 7$, $t - 30$ para la zona z
rolling_mean_7	Media de $Y_{z,t}$ en los últimos 7 períodos
rolling_std_7	Desviación estándar de $Y_{z,t}$ en los últimos 7 períodos
rolling_max_30	Máximo de $Y_{z,t}$ en los últimos 30 períodos
rolling_mean_30	Media de $Y_{z,t}$ en los últimos 30 períodos

3.3.3. Features de texto libre (opcional — NLP básico)

A partir de las columnas `Observacion solicitud` y `Observación` se pueden extraer variables binarias mediante búsqueda de palabras clave:

Variable derivada	Regla de extracción
obra_terceros	1 si el texto contiene “excavacion”, “pavimentacion”, “alcantarillado”, “constructora”
intento_hurto	1 si el texto contiene “robo”, “hurtaron”, “robaron”
barrio_texto	Barrio mencionado explícitamente cuando Dirección es incompleta

3.4. Variables a excluir del modelo

Las siguientes columnas deben excluirse del entrenamiento por las razones indicadas:

Columna	Razón de exclusión
Contrato / Contacto	Identificadores de usuario — sin señal predictiva y riesgo de <i>overfitting</i>
Persona ejecuta / legaliza	Información post-hoc no disponible en el momento de la predicción
Orden / Nro_solicitud / Interaccion	IDs técnicos sin valor predictivo
Dpto_SSPD / Loca_SSPD	Constantes en todo el dataset

Columna	Razón de exclusión
Descripción del departamento / localidad	Constantes en todo el dataset
Fecha asignación (en bruto)	Se usa solo para calcular <code>tiempo_respuesta</code> ; no como feature directo
Fecha_llegada / _control / _normalizacion (en bruto)	Variables de resultado, disponibles solo después del evento

4. Variables Externas a Integrar

El dataset interno no contiene variables climáticas ni socioeconómicas. Estas corresponden a la **Variante 2** del diseño conceptual del proyecto y deben obtenerse de fuentes externas para enriquecer el modelo.

Variable	Fuente sugerida	Justificación
Variables climáticas		
Temperatura (°C)	IDEAM / Open-Meteo	Afecta dilatación de tuberías y comportamiento del suelo
Humedad relativa (%)	IDEAM / Open-Meteo	Relacionada con corrosión de acometidas subterráneas
Precipitación (mm)	IDEAM / Open-Meteo	Las lluvias intensas generan movimiento de suelo y roturas por obras
Presión atmosférica (hPa)	Open-Meteo	Variable de control en el modelado de presión de red
Variables socioeconómicas y urbanas		
Actividad constructiva por zona	Secretaría de Planeación de Montería	Las excavaciones de terceros son la principal causa externa de roturas de tubería
Densidad poblacional	DANE	Indicador de carga operativa sobre la red en cada zona
Historial de mantenimiento preventivo		
Días desde último mantenimiento preventivo por zona	Surtigas (interno — sistema de órdenes)	Zonas sin intervención reciente acumulan mayor riesgo de incidente; este indicador captura el efecto del mantenimiento diferido
Número de mantenimientos realizados en los últimos 6 meses por zona	Surtigas (interno)	Frecuencia de intervención preventiva como proxy de estado de la infraestructura

Variable	Fuente sugerida	Justificación
Tipo de mantenimiento más reciente por segmento	Surtigas (interno)	Distingue entre mantenimiento correctivo (reactivo) y preventivo (planificado); el correctivo frecuente señala zonas de riesgo elevado
Seguimiento de cuadrillas técnicas		
Número de órdenes activas por cuadrilla en el período	Surtigas (interno — sistema ORION)	Indica la carga operativa actual de cada cuadrilla; permite identificar períodos de saturación que correlacionan con alta demanda
Tiempo promedio de respuesta histórico por zona	Derivada del dataset interno	Proxy de la eficiencia operativa histórica en cada sector; zonas con tiempos altos pueden indicar baja cobertura de cuadrillas
Disponibilidad de cuadrillas por turno y zona	Surtigas (interno — planificación de turnos)	Variable operativa crítica para la predicción de capacidad de respuesta ante picos de demanda
Factores de degradación de infraestructura		
Antigüedad estimada de la tubería por segmento (años)	Surtigas (interno — GIS)	La probabilidad de falla aumenta de forma no lineal con la edad de la tubería; es el predictor de degradación más directo disponible
Material de la tubería por segmento	Surtigas (interno — GIS)	PE, hierro y cobre tienen tasas de degradación distintas; el hierro galvanizado presenta mayor susceptibilidad a corrosión
Número de incidentes previos en el mismo segmento de red	Derivada del dataset interno	Un segmento con múltiples roturas históricas tiene mayor probabilidad de reincidencia; captura el efecto de degradación acumulada
Presión operativa nominal por zona	Surtigas (interno — GIS)	Zonas operando cerca del límite superior de presión tienen mayor riesgo de falla ante perturbaciones
Índice de corrosividad del suelo por zona	IGAC / datos geológicos de Córdoba	La litología y composición del suelo de Montería (zonas arcillosas, rellenos urbanos) afecta la tasa de corrosión externa de las tuberías subterráneas

5. Resumen del Pipeline de Features

A continuación se presenta el conjunto consolidado de variables que alimentará el modelo predictivo, organizado por categoría.

5.1. Variante 1 — Variables base (solo fuentes internas)

```
# Variables temporales (derivadas de Fecha registro orden)
hora_seno, hora_coseno      # codificacion ciclica de la hora
dia_semana_seno, dia_semana_coseno
mes_seno, mes_coseno
semana_anio
es_fin_semana               # binaria
es_festivo                  # binaria

# Variables operativas
tipo_incidente              # categorica estandarizada de
    Causal solicitud
es_controlada               # 1 = Controlada, 0 = No
    Controlada
tipo_trabajo                # cod. del tipo de intervencion
    requerida

# Variables espaciales
zona                        # barrio extraido de Direccion

# Features de rezago (sobre  $Y_{\{z,t\}}$  agregado)
lag_1, lag_7, lag_30
rolling_mean_7, rolling_std_7
rolling_mean_30, rolling_max_30

# Variable objetivo
Y_zona_periodo              # conteo de emergencias por zona y
    periodo
```

5.2. Variante 2 — Variables enriquecidas (fuentes internas + externas)

La Variante 2 incorpora todas las variables de la Variante 1 más las siguientes:

```
# Variables climaticas (Open-Meteo / IDEAM)
temperatura_C
humedad_relativa_pct
precipitacion_mm
presion_atm_hPa

# Variables socioeconomicas y urbanas (DANE / Planeacion)
densidad_poblacional_zona
```

```
actividad_constructiva_zona # binaria o conteo de permisos
    activos

# Variables de infraestructura (GIS Surtigas)
antiguedad_tuberia_anios    # promedio por zona
tipo_material_tuberia      # PE, hierro, cobre (categorica)

# Variables de texto (NLP basico)
obra_terceros               # 1 si hay mencion de excavacion/
    construccion
intento_hurto               # 1 si hay mencion de robo
```